神经网络在头部姿态估计研究中的应用

陈禾嘉

计算机科学与技术学院
西安电子科技大学

摘要

头部姿态估计（Head Pose Estimation）是人机互动中的重要组成部分。头部姿态估计为目光注视估计、面部表情识别以及司机驾驶疲劳程度估计等应用提供依据，这为模型的实时性与准确性提出了挑战。除了使用穿戴式传感器捕捉头部运动姿态角度外，使用 RGB 或深度图像的计算机视觉技术与方法，特别是深度神经网络建模已在近来也被广泛采用。本文首先介绍头部姿态的表示方法及广泛使用的数据集，之后讨论目前效果最好的用于计算头部姿态的估计方法的神经网络结构，试分析其优点与缺点，最后进行对比与总结。

以往研究头部姿态估计的综述，通常指关注于基于 RGB 图像的头部姿态分析，而对同时使用 RGB 和深度图的研究，还没有系统的综述。本文旨在弥补相关领域的空缺，收集、整理了来自 41 篇关于使用 RGB 及深度图的神经网络的研究成果。

1 引言

本文的结构如下：第 2 节描述头部姿态的 3 种数据表示方法，即欧拉角表示法、旋转矩阵表示法及单位四元数表示法。第 3 节评价用于训练神经网络的各种头部姿态标注数据集。第 4 节描述基于深度图及同时使用 RGB 和深度图训练神经网络模型的重要性。第 5 节给出本文结论。

2 头部姿态表示方法

头部姿态表示的方法继承了对 3D 刚体旋转的表示，从事头部姿态计算的研究者们不断从 3D 刚体的旋转方法中寻求灵感，基于头部旋转是 3D 刚体旋转的假设，将 3D 刚体旋转的表示方法引入头部姿态表示中。

2.1 欧拉角表示法

2009 年，Murphy-Chutorian 等人 [1] 指出广泛使用三维自由度（degree of freedom）来表示头部姿态。如图 1所示，三维自由度由倾斜（pitch）、平摆（yaw）与旋转（roll）组成，并且每一个维度均由欧拉角度进行度量。

目前，绝大多数头部姿态估计的研究都是以欧拉角的方式进行表示的。然而，在 2005 年 Lepetit 等人 [2] 就已经提出欧拉角表示头部姿态时，同样会存在表示三维物体的旋转的万向锁（gimbal lock）问题，即有时小的旋转变化会引起一个或多个欧拉角的显著变化。

在 3D 旋转表示的问题中，为了防止万向锁问题的发生，Ayache 等人 [3] 于 1989 年提出了旋转矩阵表示，而 Shoemake 等人 [4] 在 1985 年提出的单位四元数表示法。

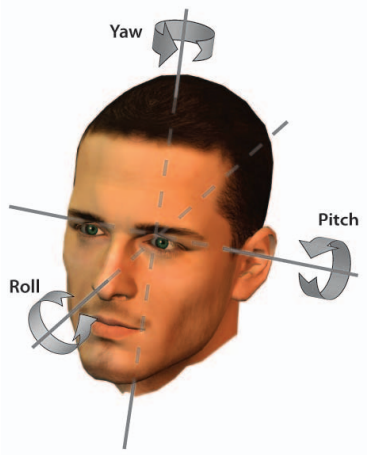

图 1: 欧拉角表示

2.2 旋转矩阵表示法

旋转矩阵表示法是对欧拉角表示法的简单改造。具体地，在三维空间中，在使用三个正交的向量，对欧拉角进行替换。三个向量的指向由具体模型的表示而决定，例如图 2中，三个向量分别指向头部面向方向、头部相对左侧与头部相对正上方。

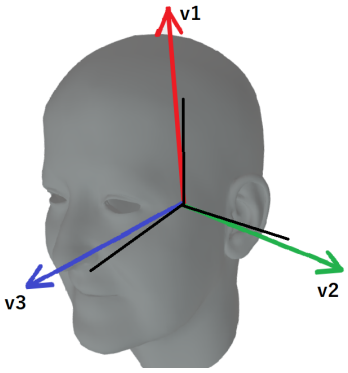

图 2: 旋转矩阵表示法

使用旋转矩阵表示法的确可以避免欧拉角表示法中存在的万向锁问题，但是对于三个向量，即 9 个元素，相对于欧拉角三维自由度的 3 个元素，从数量上大大增加了模型训练的参数，为提高了模型训练的复杂程度。并且，模型训练还同时兼顾旋转矩阵对头部姿态的估计准确程度，以及三个向量之间的正交情况。

2.3 单位四元数表示法

单位四元数（Quaternion）是单位长度的 4 分量矢量，描述了一个旋转轴和一个旋转角度以 $\boldsymbol{q} = (q_x, q_y, q_z, q_\omega)$ 表示，单位四元数处于单位球 $\| q \| = 1$ 上。除对偶覆盖外，旋转的单位四元数表示是唯一且连续的。

同样，单位四元数也避免了万向锁问题。并且，相对于旋转矩阵，单位四元数仅需要 4 个元素来描述旋转，这相对于旋转矩阵减少 5 个元素，降低了神经网络的训练难度。

3 头部姿态的标注数据集

在本节中，我们将着重介绍目前在 RGB 与深度域中使用最为广泛的 BIWI 数据集，并且兼顾仅采用 RGB 图像的数据集。同时将会列举一些与头部姿态估计相关的数据集。

3.1 BIWI 头部姿态数据集

BIWI 头部姿态数据集 [5]（简称 BIWI）收集了由 20 个志愿者录制的 24 段视频（部分志愿者录制了两段视频），并且提供了视频中每一帧志愿者头部的姿态，如图 3。该数据集含有约 1.5 万帧，并且同时提供了 RGB 与深度图片，以及使用旋转矩阵表示的真值。为了引入光源的变化，数据集中含有两个不同的光源下录制，并且有志愿者同时出现在两种光源采集的过程中。数据集采用 Kinect v1 录制，其中深度图像中的背景根据阈值大小被删除。

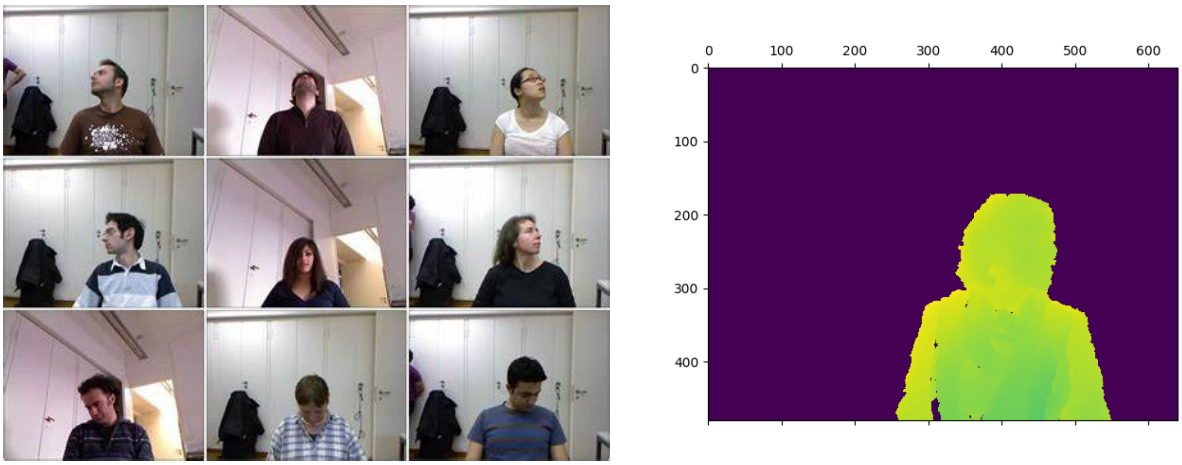

(a) 多人多角度的 RGB 图例

(b) 一帧深度图例

图 3: BIWI 数据集样本

但是，BIWI 数据集某一些帧的背景中出现了其它成员，这会对一些模型，尤其是依赖于人脸定位的模型增加训练难度。

在使用 BIWI 数据集用于训练与验证模型准确度时，数据集本身并没有指定测试集，因此比较的公平性并不能得到有效保证。目前使用 BIWI 数据集通常采用了两套评测方法：POSEidon[6] 与 Head PointNet[7] 等将第 11 与 12 号视频序列用于测试，TriNet[8]，HopeNet[9] 以及 FSA-Net[10] 使用了交叉验证。

3.2 ICT-3DHP 数据集

ICT-3DHP 数据集 [11] 使用 Kinect v1 录制了 10 个志愿者（6 名男性与 4 名女性）的姿态变化。在公开下载的版本中，每一个志愿者的 RGB 图像使用视频格式保存，而深度图像以 png 文件保存。志愿者头部姿态的真值是通过在录制过程中佩戴在头部的传感器记录的用六维向量表示的。

由于连续的 RGB 图片是以视频的形式保存的，因此会存在 RGB 图与深度图不能逐帧一一对应的情况。与 BIWI 数据集类似，ICT-3DHP 数据集同样也没有指定训练集与测试集的划分。

3.3 AFLW2000-3D 数据集

AFLW2000-3D 数据集 [12] 包含来自于 AFLW 数据集的前两千张 RGB 图片，其图片之间没有联系，且不含有深度图像。数据集标定了光源信息、头部姿态角度以及面部关键点。其中，三维的 68 个坐标点被完整地定位。而二维关键点仅保留图中可见的，其余因角度遮挡的关键点并没有被标记。

相比于上文所述数据集，AFLW2000-3D 含有更复杂的光源，但是从数据集的体量上远远不足，并且其主要目的是用于面部关键点的定位，所以往往不会单独被用来训练模型。

3.4 300W 与 300W-LP 数据集

300W 数据集 [13, 14, 15] 是 RGB 图片域中对头部姿态估计最为常用的数据集，含有 3837 张图片。与前面的数据集不同，这个数据集指定了 3148 张用于训练，689 张用于测试。但是该数据集仅标定了二维平面内的 68 个面部关键点。

300W-LP 是 300W 中头部姿态角度相对较大的图片集合，包含了来自以下数据集的 61225 张图片：AFW，LFPW，IBUG 以及 HELEN。数据集中提供的信息与 AFLW2000-3D 一致，但是被遮挡的二维面部坐标得以保留。

3.5 ETH 面部姿态数据集

ETH 面部姿态数据集 [16]（ETH face pose range image dataset，下文简称 ETH-FPR）中使用了一种不常见的鼻尖向量表示法，即使用鼻尖指向前方的三维向量表示，如图 4所示。

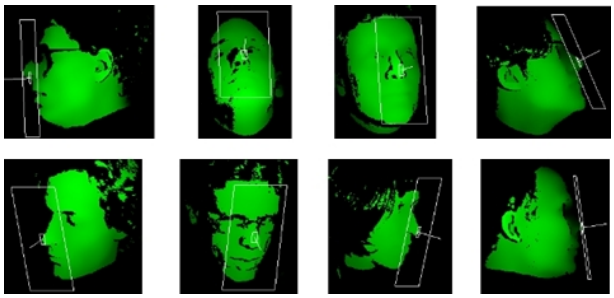

图 4: ETH-FPR 数据集样本

该数据集的表示方法使其丢失了旋转的头部姿态信息，因此该数据集已经不再使用。

3.6 其他相关数据集

IAS-LabRGB-深度面部数据集记录了 26 个志愿者的 13 个特征，包含了头部姿态、光源以及表情等信息，但是其姿态仅标定为正向或非正向的二元离散信息，因此不适用于头部姿态估计；BU-3DFE 数据集 [17] 提出了一个新开发的三维面部表情数据库，其中包括原型三维面部表情形状和来自 100 名志愿者的 2500 个模型的二维面部纹理；2020 年公开的 ETH XGaze 数据集 [18] 是一个全新的面向目光注视的数据集，其中包含了一百万张在极端头部姿态下的目光注视角度，其中的头部姿态同样被标注，因此该数据集是 ETH-FPR 数据集的完美替代品，并且可以补充上述数据集在极端角度下样本量过少的问题，因此，ETH XGaze 数据集将有可能成为今后模型训练的主要选择。

3.7 各数据集指标比较

为了直观的对比上述数据集，根据其广泛使用的程度，将其各指标列入表 1中。

数据集	图片类型	数量	真值表示方式	深度表示方法	背景是否降噪
BIWI[5]	RGB 与深度	24 组/15679 张	旋转矩阵	距离（毫米）	仅深度图
ICT-3DHP[11]	RGB 与深度	10 组/14202 张	Polhemus norm	距离（毫米）	仅深度图
AFLW2000-3D[12]	RGB	2000 张	欧拉角、关键点	-	-
300W[13, 14, 15]	RGB	3837 张	关键点	-	-
300W-LP [12]	RGB	61255 张	欧拉角、关键点	-	-
ETH-fpr[16]	深度	10 组/10545 张	鼻尖向量	点云	深度图

表 1: 各数据集一览表

4 头部姿态的计算方法

头部姿态估计通常以是否根据面部特征作为分类的标准，但是无论是哪一种方法，都首先应是建立在头部定位的基础上。因此，在本节中首先介绍目前现有的头部定位方法，之后简要介绍基于面部特征的姿态估计，最后着重介绍非基于面部特征的姿态估计。

4.1 头部定位：前提

我们可以直接将头部定位的问题视为面部定位进行处理，在最终的定位的区域上进行适当放缩，得到头部区域。对于 RGB 图片的头部定位方法，OpenCV 中提供了正面头部定位的 API 接口，可以直接调用。但是该接口建立在面部正视的基础上，当角度过大时，接口的准确率会大大下降，因此往往用于其它头部定位模型的比较。2016 年提出的 MTCNN[19] 和 SSD[20] 是成熟的面部检测神经网络模型，而 SSD 在速度上相对于 MTCNN 模型更为快捷，若是模型要求实时性，则使用 SSD 面部检测较为合适。最新的头部定位方法还有 2018 年提出的 RetinaFace[21, 22, 23, 24]，以及在三维空间中的定位 [25]。

4.2 基于面部特征的估计

基于面部特征的估计往往是建立在人脸对齐的基础上，其主要流程是：首先在图片中进行人脸定位，之后定位面部的二维或三维关键点，最后由关键点的位置计算头部姿态角度。此类方法的神经网络主要用于训练人脸的定位问题以及面部关键点的定位问题，而在现阶段的绝大多数神经网络在训练的过程中同时解决人脸以及关键点定位 [26]，如 MTCNN 神经网络模型会直接估计面部的区域（头部定位问题）以及两眼、嘴角两侧以及鼻子 5 个面部关键点的坐标（关键点定位问题）。在获得了面部关键点的坐标后，可以根据求解 3D-2D 点对运动的 PnP 算法（Pespective-N-Point）得出头部姿态角度[1]。

因此，目前基于面部特征的估计问题已经由面部对齐，即面部关键点定位问题所取代。目前面部对齐的方法已经逐步精确 [26, 27]，但通常不会估算其预测位置的不确定性，也无法预测标志是否可见。在 2020 年，Kumar 等人 [28] 提出了一种框架，用于预测关键点位置，这些预测位置的不确定性和地标性。由此建立了新的面向关键点的数据集 LUVLi，手动标记 68 个面部特征的真实位

[1] 具体实现可参考：*https://github.com/brionmario/pnp-head-pose-estimation-poc*

置，并附加信息，包括每个面部特征是未被遮挡，自身被遮挡（由于极端的头部姿势）还是外部被遮挡，弥补了 3.3节中 AFLW2000-3D 数据集在遮挡问题上的空缺。

4.3 非基于面部特征的估计

4.3.1 RGB 输入

对于仅使用 RGB 图片的情况，通常使用卷积神经网络作为骨干网络。2015 年 ConvNet [29] 仅使用了多卷积层以及 ReLu 激活函数的方式进行计算。而 HopeNet [9] 以及 TriNet [8] 等在 2018 年至 2021 年使用了 ResNet50 作为骨干网络。QuatNet[30] 基础网络采用 GoogLeNet 神经网络模型，最后一层池化层被替换为一个回归神经网络（Regression net）和多个顺序神经网络（Ranking net）。使用性能更好的骨干网络可以从源头上提高模型的性能。例如收录于 CVPR2021 的 RepVGG 神经网络 [41] 仅使用了卷积层与 ReLu 激活函数，没有采用分支结构，却在性能上达到领先水平，可以预见到 RepVGG 会在头部姿态估计中发挥作用。

头部定位与头部姿态识别两个步骤合二为一的方法也可以提高模型的性能。在 2020 年提出的 img2pose 模型中，Albiero 等人 [31] 提出了六维自由度的方式，摆脱了人脸检测以及关键点定位的需求。此前常规的人脸检测 + 关键点定位的模式存在着较高的计算成本，并且关键点检测器通常针对由特定人脸检测器生成的边界框特性进行优化，因此一旦人脸检测器更新，关键点检测器就需要重新进行优化。当处于人脸密集的场景中，准确定位标准的 68 个人脸关键点会变得非常困难，进而加大了估计其姿态和人脸对齐的难度。该团队使用小而快的 ResNet18 骨干网络构建 img2pose 模型，发现该模型在实时运行时（Real Time Estimation）性能超越当前最优的头部姿态估计器，还在关键点检测方面超越了具备类似复杂度的模型。

4.3.2 深度与混合输入

对于使用深度图片及混合图片的情况，首先需要考虑如何处理深度图像的信息。

2017 年，Borghi 等人提出的 POSEidon[6] 使用了三种方法，以三流（three-stream）的方式估计：1）直接作为卷积神经网络的输入，2）训练一个将深度图转化映射为灰度图神经网络，将灰度图结果作为卷积神经网络的输入，3）使用 Farneback 算法 [32]，将帧间的变化的以光流的形式输入卷积神经网络中。虽然 Borghi 等人根据其最后的输入为深度图像，由此声称该模型工作在深度域中，但是由深度图映射为灰度图的神经网络采用了灰度图像进行训练。因此，若将该模型的准确程度与其他仅使用深度图进行训练的模型相比较是有失公正的。

使用深度图转换为灰度图的方法是新颖的，其效果如图 5所示。但是仍存在一些有待改进的地方：对于训练样本中的背景存在的干扰因素（线材、门把手）出现在了由深度图像映射得到的灰度图像中，在图中用红色方框标记。而在测试样本的背景中也出现了由门把手产生的噪声。问题的原因是数据集仅对深度图进行了背景降噪处理，而没有对灰度图降噪。

Xiao 等人 [7] 在 2020 年将深度图转化为点云的形式，并使用基于点云粗配准（Coarse Global Registeration）的 PointNet++ 模型 [33] 作为骨干网络，提取点云中的特征，将特征输入全连接层进行回归。而 2015 年 Li 等人 [34] 使用了精配准（Fine Local Registeration）的 ICP（Iterative Cloud Point）算法而非神经网路模型进行头部姿态估计，但是 ICP 算法需要初始化，即提供初始姿态，这不便于模型后期的使用。

图 5: BIWI 数据集深度转换灰度图结果，来自 POSEidon[6]。其中第一行为灰度图像的真值，第二行为深度图像，第三行为预测结果。第一至四列用于训练，而第五、六列用于测试。红色方框为本文添加。

4.4 有序回归

除了全连接层的堆叠外，越来越多的模型 [7, 26, 35, 30] 开始采用有序回归的方法提高准确度。有序回归是解决类别之间有某种顺序关系的模型，通常用于年龄预测等类别之间存在顺序关系的问题。有序回归学习去预测标签（label）的排序，而非标签值本身，当标签的顺序扮演着更加重要的角色相比于它们实际的数值，这是非常重要和有效的。Hsu 等人 [30] 提出，当人脸平摆欧拉角度小于 20° 时，面部特征不会发生显著变化。于是将连续的角度切分为箱（bin），并以此作为有序回归的标签去学习。

4.5 比较标准与模型比较

神经网络模型的性能主要体现在**实时性**与**准确性**两方面。对于**实时性**的评价，需要考虑到具体使用的计算机的计算能力。通常使用的比较实时性指标的方式是模型每秒钟处理的帧的个数（fps，frame per second）。Li 等人 [34] 使用的非神经网络方法在 2015 年主频为 2.93GHz 的英特尔酷睿 i7 处理器上运行速度达到了 47fps，可以作为神经网络模型的参考。CVPR2021 收录的 img2pose 模型在单片英伟达泰坦 Xp 显卡上运行速度为 41fps，是目前神经网络模型可以达到的最快水平。

比较模型估计**准确性**的标准因采用的不同表示方法而异。目前针对欧拉角三维自由度的表示方法，广泛使用的比较模型估计性能的指标是平均绝对误差（MAE，Mean Average Error），对于某一个自由度的误差计算而言，如公式 1所示。

$$\mathrm{MAE} = \frac{1}{m}\sum_{i=1}^{m}|y_i - \hat{y}_i| \tag{1}$$

其中，m 表示用于测试的样本数量。计算某一维度的 MAE 可以比较在模型内部对于倾斜、平摆以及旋转的估计性能。而对于欧拉角模型整体的估计，采用三个维度的 MAE 的平均值表示，表示如公式 2。

$$\mathrm{MAE} = \frac{1}{3}\sum_{j}\mathrm{MAE}_j, \quad j \in \{pitch, yaw, roll\} \tag{2}$$

而对于旋转矩阵以及四元数表示法，都存在与 MAE 相似的比较衡量标准。目前使用除欧拉角表示法之外，只有少数模型选择使用不同的表示方法。TriNet [8] 在 2021 年使用了向量平均绝对误差（MAEV，Mean Average Error of Vector）来表示，而在 2019 年的 QuatNet [30] 中使用了四元

数平均绝对误差（QMAE，Quaternion Mean Absolute Error）来衡量。对于提及的两个采用不同表方法的模型，为了与其他现有模型进行比较，均通过改变神经网络输出层神经元的个数使其重新验证得到 MAE，不存在直接转为 MAE 的方法。

表 2中选择并记录了上述计算头部姿态的方法中具有一定代表性的方法，列举其**准确性**及使用的训练数据集。其中 Meyer 等人的模型因为使用了 ETH-FPR 数据集，使其验证性能时 MAE 中的旋转一项缺失。

方法	提出年份	倾斜	平摆	旋转	MAE	输入	数据集
Fanelli[36]	2011	8.9	8.5	7.9	8.43	D	BIWI
Padeleris[37]	2012	2.4	3	2.8	2.70	D	BIWI
Papazov[38]	2015	2.5	1.8	2.9	2.15	RGBD	BIWI
Meyer[39]	2015	2.1	2.1	2.4	2.20	D	BIWI
		2.9	2.3	-	2.60		ETH-FPR
Li *et.al* [34]	2015	1.7	2.2	3.2	2.37	RGBD	BIWI
ConvNet[29]	2015	5.1	4.2	2.4	3.9	RGB	300W
POSEidon[6]	2016	1.6±1.7	1.8±1.8	1.7±1.5	1.7±1.7	RGBD	BIWI
Derkach[40]	2017	7.8	6.7	5.3	6.60	D	SASE
HopeNet[9] (alpha = 1)	2018	4.81	6.606	3.269	4.90	RGB	AFLW2k3d
		6.92	6.637	5.674	6.41		BIWI
HopeNet (alpha = 2)		5.167	6.975	3.388	5.18		AFLW2k3d
		6.47	6.559	5.436	6.16		BIWI
img2pose[31]	2020	4.4	5.5	2.8	4.23	RGB	AFLW2k3d
		3.97	5.267	2.46	3.90		BIWI
Head PointNet[7]	2020	2.2±1.6	1.6±1.4	2.3±1.7	2.0±1.5	D	BIWI

表 2: 代表性头部姿态估计模型的准确性列举

5 结论

虽然在模型的比较中，使用深度以及混合的模型相较于同期仅使用 RGB 图像进行分析的模型在性能上好。但是深度摄像头因为价格而存在较高门槛，因此在实际工程中，往往需要在性能与成本上进行取舍。

当考虑如何提升深度以及混合神经网络模型的性能时，可以根据本文讨论内容从以下的几个角度出发：

1. 使用更加丰富的数据集进行训练
2. 深度图的处理方式
3. 采用性能更优的神经网络作为模型的骨干

综上所述，为了提高模型的准确性，可以采用更加全面的数据集；深度图或是 RGB 与深度混合的情况可以使用多种处理方式，并采用多流（Multi-stream）的方式设计神经网络；采用优秀的神经网络模型可以同时提高神经网络模型的准确性与实时性，因此头部姿态估计的研究者们需要时刻关注于当前神经网络性能上的突破。

随着神经网络模型的性能不断提高，头部姿态估计的能力将会在不同的领域展现出更多的用途，这将会为人们的生活提供更多的便利，从而改变人们的生活方式。

参考文献

[1] E. Murphy-Chutorian and M. M. Trivedi. Head pose estimation in computer vision: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 31(4):607–626, 2009.

[2] Vincent Lepetit and Pascal Fua. *Monocular model-based 3D tracking of rigid objects*. Now Publishers Inc, 2005.

[3] Nicholas Ayache and Olivier Faugeras. Maintaining representations of the environment of a mobile robot. *IEEE transactions on Robotics and Automation*, 5(6):804–819, 1989.

[4] Ken Shoemake. Animating rotation with quaternion curves. In *Proceedings of the 12th annual conference on Computer graphics and interactive techniques*, pages 245–254, 1985.

[5] Gabriele Fanelli, Matthias Dantone, Juergen Gall, Andrea Fossati, and Luc Van Gool. Random forests for real time 3d face analysis. *Int. J. Comput. Vision*, 101(3):437–458, February 2013.

[6] Guido Borghi, Marco Venturelli, Roberto Vezzani, and Rita Cucchiara. Poseidon: Face-from-depth for driver pose estimation. In *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5494–5503, 2017.

[7] Shihua Xiao, Nan Sang, Xupeng Wang, and Xiangtian Ma. Leveraging ordinal regression with soft labels for 3d head pose estimation from point sets. In *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 1883–1887. IEEE, 2020.

[8] Zhiwen Cao, Zongcheng Chu, Dongfang Liu, and Yingjie Chen. A vector-based representation to enhance head pose estimation. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1188–1197, January 2021.

[9] Nataniel Ruiz, Eunji Chong, and James M. Rehg. Fine-grained head pose estimation without keypoints. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, June 2018.

[10] Tsun-Yi Yang, Yi-Ting Chen, Yen-Yu Lin, and Yung-Yu Chuang. Fsa-net: Learning fine-grained structure aggregation for head pose estimation from a single image. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1087–1096, 2019.

[11] Tadas Baltrušaitis, Peter Robinson, and Louis-Philippe Morency. 3d constrained local model for rigid and non-rigid facial tracking. In *2012 IEEE conference on computer vision and pattern recognition*, pages 2610–2617. IEEE, 2012.

[12] Xiangyu Zhu, Zhen Lei, Xiaoming Liu, Hailin Shi, and Stan Z. Li. Face alignment across large poses: A 3d solution. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2016.

[13] C. Sagonas, G. Tzimiropoulos, S. Zafeiriou, and M. Pantic. 300 faces in-the-wild challenge: The first facial landmark localization challenge. In *2013 IEEE International Conference on Computer Vision Workshops*, pages 397–403, 2013.

[14] Christos Sagonas, Epameinondas Antonakos, Georgios Tzimiropoulos, Stefanos Zafeiriou, and Maja Pantic. 300 faces in-the-wild challenge: database and results. *Image and Vision Computing*, 47:3–18, 2016. 300-W, the First Automatic Facial Landmark Detection in-the-Wild Challenge.

[15] C. Sagonas, G. Tzimiropoulos, S. Zafeiriou, and M. Pantic. A semi-automatic methodology for facial landmark annotation. In *2013 IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 896–903, 2013.

[16] Michael D. Breitenstein, Daniel Kuettel, Thibaut Weise, Luc Van Gool, and Hanspeter Pfister. Real-time face pose estimation from single range images. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR'08)*, June 2008.

[17] Lijun Yin, Xiaozhou Wei, Yi Sun, Jun Wang, and Matthew J Rosato. A 3d facial expression database for facial behavior research. In *7th international conference on automatic face and gesture recognition (FGR06)*, pages 211–216. IEEE, 2006.

[18] Xucong Zhang, Seonwook Park, Thabo Beeler, Derek Bradley, Siyu Tang, and Otmar Hilliges. Eth-xgaze: A large scale dataset for gaze estimation under extreme head pose and gaze variation. In *European Conference on Computer Vision (ECCV)*, 2020.

[19] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao. Joint face detection and alignment using multitask cascaded convolutional networks. *IEEE Signal Processing Letters*, 23(10):1499–1503, Oct 2016.

[20] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu, and Alexander C. Berg. Ssd: Single shot multibox detector. In *Computer Vision – ECCV 2016*, pages 21–37. Springer International Publishing, 2016.

[21] Jiankang Deng, Jia Guo, Xue Niannan, and Stefanos Zafeiriou. Arcface: Additive angular margin loss for deep face recognition. In *CVPR*, 2019.

[22] Jiankang Deng, Anastasios Roussos, Grigorios Chrysos, Evangelos Ververas, Irene Kotsia, Jie Shen, and Stefanos Zafeiriou. The menpo benchmark for multi-pose 2d and 3d facial landmark localisation and tracking. *IJCV*, 2018.

[23] Jia Guo, Jiankang Deng, Niannan Xue, and Stefanos Zafeiriou. Stacked dense u-nets with dual transformers for robust face alignment. In *BMVC*, 2018.

[24] Jiankang Deng, Jia Guo, Zhou Yuxiang, Jinke Yu, Irene Kotsia, and Stefanos Zafeiriou. Retinaface: Single-stage dense face localisation in the wild. In *arxiv*, 2019.

[25] Richard T Marriott, Sami Romdhani, and Liming Chen. A 3d gan for improved large-pose facial recognition. *arXiv preprint arXiv:2012.10545*, 2020.

[26] Amit Kumar, Azadeh Alavi, and Rama Chellappa. Kepler: Keypoint and pose estimation of unconstrained faces by learning efficient h-cnn regressors, 2017.

[27] Marek Kowalski, Jacek Naruniec, and Tomasz Trzcinski. Deep alignment network: A convolutional neural network for robust face alignment. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 88–97, 2017.

[28] A. Kumar, T. K. Marks, W. Mou, Y. Wang, M. Jones, A. Cherian, T. Koike-Akino, X. Liu, and C. Feng. Luvli face alignment: Estimating landmarks' location, uncertainty, and visibility likelihood. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8233–8243, 2020.

[29] Heng Yang, Wenxuan Mou, Yichi Zhang, Ioannis Patras, Hatice Gunes, and Peter Robinson. Face alignment assisted by head pose estimation. *arXiv preprint arXiv:1507.03148*, 2015.

[30] Heng-Wei Hsu, Tung-Yu Wu, Sheng Wan, Wing Hung Wong, and Chen-Yi Lee. Quatnet: Quaternion-based head pose estimation with multiregression loss. *IEEE Transactions on Multimedia*, 21(4):1035–1046, 2018.

[31] Vítor Albiero, Xingyu Chen, Xi Yin, Guan Pang, and Tal Hassner. img2pose: Face alignment and detection via 6dof, face pose estimation. In *CVPR*, 2021.

[32] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Image Analysis*, pages 363–370, 2003.

[33] Charles R Qi, Li Yi, Hao Su, and Leonidas J Guibas. Pointnet++: Deep hierarchical feature learning on point sets in a metric space. *arXiv preprint arXiv:1706.02413*, 2017.

[34] Songnan Li, King Ngi Ngan, Raveendran Paramesran, and Lu Sheng. Real-time head pose tracking with online face template reconstruction. *IEEE transactions on pattern analysis and machine intelligence*, 38(9):1922–1928, 2015.

[35] Axel Berg, Magnus Oskarsson, and Mark O'Connor. Deep ordinal regression with label diversity. *arXiv preprint arXiv:2006.15864*, 2020.

[36] Gabriele Fanelli, Thibaut Weise, Juergen Gall, and Luc Van Gool. Real time head pose estimation from consumer depth cameras. In *Pattern Recognition*, pages 101–110, Berlin, Heidelberg, 2011. Springer Berlin Heidelberg.

[37] P. Padeleris, X. Zabulis, and A. A. Argyros. Head pose estimation on depth data based on particle swarm optimization. In *2012 IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops*, pages 42–49, 2012.

[38] C. Papazov, T. K. Marks, and M. Jones. Real-time 3d head pose and facial landmark estimation from depth images using triangular surface patch features. In *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4722–4730, 2015.

[39] Gregory P. Meyer, Shalini Gupta, Iuri Frosio, Dikpal Reddy, and Jan Kautz. Robust model-based 3d head pose estimation. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, December 2015.

[40] Dmytro Derkach, Adria Ruiz, and Federico M Sukno. Head pose estimation based on 3-d facial landmarks localization and regression. In *Automatic Face & Gesture Recognition (FG 2017), 2017 12th IEEE International Conference on*, pages 820–827. IEEE, 2017.

[41] Xiaohan Ding, Xiangyu Zhang, Ningning Ma, Jungong Han, Guiguang Ding, and Jian Sun. Repvgg: Making vgg-style convnets great again. *arXiv preprint arXiv:2101.03697*, 2021.